



**Réseaux convolutifs pour l'analyse d'image en microscopie par ptychographie de Fourier
et application à la malaria**

Juliana do Nascimento Damurie da Silva

Évry
2020

Juliana do Nascimento Damurie da Silva

**Réseaux convolutifs pour l'analyse d'image en microscopie par ptychographie de Fourier
et application à la malaria**

Travail présenté dans le Master Traitement de l'Information et Exploitation des Données de l'Université de Versailles Saint-Quentin-en-Yvelines et Télécom SudParis comme un rapport de stage de fin d'études.

Spécialité: *Intelligence computationnelle*
Encadré par: *Patrick Horain*

Évry
2020

REMERCIEMENTS

Je tiens à remercier le professeur Patrick Horain, pour son aide dans la résolution des problèmes et le suivi du développement de ce travail, qui a été très important pour mon développement personnel, et aussi pour l'opportunité de travailler sur ce projet.

Je souhaite aussi remercier l'ensemble de l'équipe pédagogique du master TRIED, de Télécom SudParis et de l'Université de Versailles Saint-Quentin-en-Yvelines pour l'encadrement accordé tout au long de mon cursus.

Je tiens également à remercier ma famille pour tout le soutien et l'expérience qui m'ont permis d'en arriver là.

Je remercie également Luiza Lopes, mon duo d'échange, pour toute l'aide et la camaraderie qu'elle m'a apportées pendant le cours.

Et enfin, je remercie Evaristo Luís pour toute l'aide qu'il a apportée aux corrections et au soutien.

LISTE DES ACRONYMES

CTF	<i>Coherent Transfer Function</i>
FP	<i>Fourier Ptychography</i>
FPM	<i>Fourier ptychographic microscopy</i>
LED	<i>Light-emitting Diode</i>
NA	<i>Numerical Aperture</i>
PCR	Réaction en Chaîne par Polymérase
PSF	<i>Point Spread Function</i>
SBP	<i>Space-bandwidth product</i>

TABLE DES MATIÈRES

1	INTRODUCTION	5
1.1	PRÉSENTATION DU LABORATOIRE	5
1.2	CONTEXTE	5
1.3	OBJECTIFS	6
2	FONDEMENT THÉORIQUE ET ÉTAT DE L'ART	7
2.1	LA MICROSCOPIE PAR PTYCHOGRAPHIE SPECTRALE (FPM)	7
2.2	RECONSTRUCTION PAR RÉSEAUX NEURONAUX ET APPRENTISSAGE	10
3	LES APPROCHES ÉTUDIÉES	11
3.1	MODÉLISATION DE LA FPM AVEC LE RÉSEAU DE NEURONES	11
3.2	MISE EN œUVRE	16
3.3	MODÈLE DE RÉSEAU NEURONAL POUR LA RECONSTRUCTION D'IMAGES AVEC FPM ET RECONSTRUCTION DE LA PUPILLE	18
3.4	ENSEMBLE DES DONNÉS	21
3.4.1	Estimation du positionnement des LEDs	21
3.4.2	Atténuation du bruit sur imagettes	23
3.5	MÉTHODE FINALE	25
3.5.1	Segmentation	25
3.5.2	Augmentation des Donnés	25
3.5.3	Classification	25
4	RÉSULTATS	27
5	CONCLUSION	32
	REFERENCES	33
6	ANNEXE	35
6.1	POLYNÔMES DE ZERNIKE	35

1

INTRODUCTION

1.1 PRÉSENTATION DU LABORATOIRE

Télécom SudParis est une grande école publique d'ingénieurs reconnue au meilleur niveau des sciences et technologies du numérique. La qualité de ses formations est basée sur l'excellence scientifique de son corps professoral et une pédagogie mettant l'accent sur les projets d'équipes, l'innovation de rupture et l'entrepreneuriat. Télécom SudParis compte 1 000 étudiants dont 700 élèves ingénieurs et près de 180 doctorants. Télécom SudParis fait partie de l'IMT (Institut Mines-Télécom), premier groupe d'école d'ingénieurs en France, sous tutelle du ministre en charge de l'Industrie. Elle partage un campus international avec Institut Mines-Télécom Business School. Elle est co-fondatrice de l'Institut Polytechnique de Paris (IP Paris), un Institut de Sciences et Technologies à vocation mondiale sur le plateau de Saclay avec l'Ecole polytechnique, l'ENSTA Paris, l'ENSAE Paris et Télécom Paris.

Mon stage s'est déroulé pendant 6 mois au département EPH (Electronique et Physique) partie de Télécom SudParis, un groupe d'enseignants-chercheurs spécialisés dans le soutien des systèmes de télécommunications et le développement d'activités liées aux interactions homme-machine. Le département compte actuellement une équipe de 21 enseignants-chercheurs, un responsable de la gestion et un assistant.

Les activités du laboratoire de recherche de l'EPH sont divisées en quatre groupes principaux : le groupe Optique- Photonique, le groupe Intermédia , le groupe de navigation et le groupe Hyperfréquence et Communication.

Ce travail fait partie du groupe Intermedia. Le groupe Intermedia étudie et réalise des systèmes de communication entre l'homme et la machine. Nous considérons différentes interfaces (par le geste, le stylo, les capteurs biométriques et biomédicaux), de l'acquisition des données, du traitement du signal et même de la reconnaissance (interprétation du signal ECG, acquisition et suivi du geste, vérification biométrique de l'identité, etc.) Pour cela, nous avons développé des techniques originales d'apprentissage statistique (filtrage particulaire, réseaux de neurones, modèles de Markov cachés, réseaux bayésiens), de fusion de données et de vision artificielle 2D ou 3D.

Le département est situé sur deux sites (Évry, Palaisau), le présent travail a été développé sur le site d'Évry.

1.2 CONTEXTE

Le paludisme (la malaria) est une maladie transmise par des moustiques Anophèles femelles infectées par des parasites de la famille du plasmodium. Les parasites se déposent dans le tissu hépatique et après un certain temps, ils créent des ruptures dans les globules rouges. Selon l'Organisation mondiale de la santé, en 2018, le nombre de décès dus au paludisme était de 405 000 (1). Le diagnostic précoce du paludisme réduit le risque de décès et contribue également à réduire le nombre de cas.

Cependant, le diagnostic de laboratoire le plus couramment utilisé aujourd’hui dans les zones endémiques est la recherche de ruptures causées par des parasites dans les globules rouges à partir d’un échantillon de sang dopé avec une coloration. Hors, cette méthode nécessite l’identification par un professionnel spécialisé et est sujet à l’erreur humaine si le nombre de cellules contaminées est faible. Une autre forme de diagnostic est l’utilisation de la Réaction en Chaîne par Polymérase (PCR), qui présente une grande sensibilité dans le diagnostic mais qui est coûteuse, ce qui rend son utilisation peu avantageuse dans les zones endémiques qui nécessitent une analyse à grande échelle. Ainsi, le développement de méthodes plus précises peut améliorer l’identification précoce des personnes infectées.

La microscopie par ptychographie spectrale (*Fourier Ptychographic Microscopy*, FPM) permet de reconstruire des images d’intensité et de phase à partir de plusieurs captures d’images sous différents angles d’éclairage.⁽²⁾ Ainsi, on obtient en même temps une image en haute résolution avec un grand champ de vision, au-delà de la limitation de l’ouverture numérique des systèmes d’imagerie classique. Les différences de phase du champ optique qui sont reconstruites permettent de visualiser des structures invisibles au microscope classique. C’est-à-dire permettre la visualisation de détails dans des échantillons biologiques qui n’étaient visibles précédemment qu’avec l’utilisation de colorants, et ainsi permettre également l’étude de cellules vivantes.

Dans le cadre des travaux actuels, afin de créer une méthode d’identification des globules rouges contaminés par le parasite de la malaria, nous utiliserons des acquisitions par *Fourier ptychographic microscopy* (FPM) qui permettent une reconstruction d’image en amplitude et en phase. Pour effectuer la classification de ces cellules à l’aide des images reconstruites, nous utiliserons le réseau neuronal convolutif développé par l’étudiant Nicolas Gourgue dans ses précédents travaux avec ce même ensemble de données mais il n’a utilisé que l’image du LED central pour effectuer l’entraînement.

1.3 OBJECTIFS

Nos objectifs spécifiques dans ce travail sont les étapes suivantes :

- Étalonnage par apprentissage des paramètres d’acquisition pour une meilleure reconstruction des images.
- Reconstruction d’images d’intensité et de phase en haute résolution par FPM obtenues à partir de cellules infectées par le paludisme.
- Segmentation de ces images en amplitude et en phase.
- Classification des cellules infectées à l’aide d’informations d’amplitude et de phase.

2

FONDEMENT THÉORIQUE ET ÉTAT DE L'ART

2.1 LA MICROSCOPIE PAR PTYCHOGRAPHIE SPECTRALE (FPM)

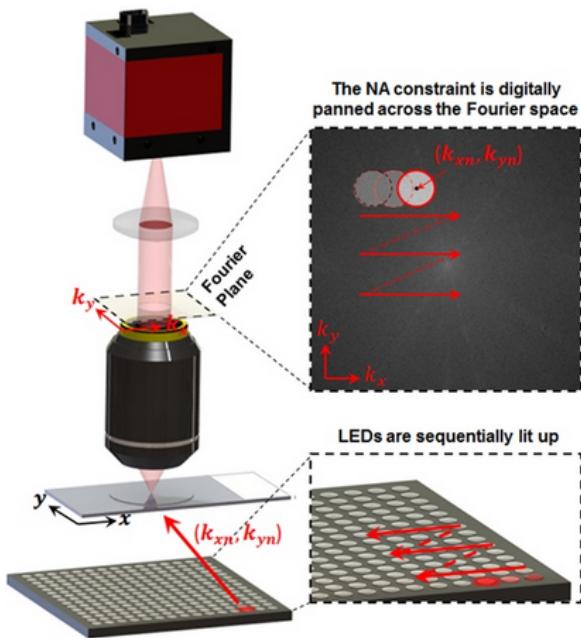


FIGURE 1: Schéma de capture d'image pour FPM. Nous avons un microscope traditionnel placé au-dessus d'un matrice de LED qui, selon la LED allumée, fournira différents vecteurs d'onde (k_{xn}, k_{yn}) . Dans le plan spectral, ces différents vecteurs d'onde ne recevront qu'une partie du plan de Fourier limité par le *Coherent Transfer Function* (CTF), qui est défini selon l'*Numerical Aperture* (NA) du microscope. Ainsi, dans le processus de base du FPM, chaque led est illuminé séparément, et nous avons alors des captures séparées de différents points du spectre de fourier, et le principe est de rassembler toutes ces parties pour former une image complète, avec une résolution plus élevée, et la différence d'angles fournit l'information de phase de l'image. Source : (3)

L'acquisition d'images par ptychographie spectrale (FPM) est un objet d'étude récent, proposé par (2). La (FPM) apporte des innovations dans le domaine de l'optique classique, qui visaient initialement à dépasser la limitation du *Space-bandwidth product* (SBP) pour la microscopie traditionnelle. Pour ces innovations, nous pouvons inclure le processus de récupération de la phase, alors que un système traditionnel, se limite à la capture de l'intensité et à la perte d'informations sur la phase. Nous pouvons également parler d'une augmentation de la résolution des images obtenues et d'une augmentation du champ de vision. Donc en termes de système physique, comme nous pouvons le voir sur la figure 1, en utilisant un microscope traditionnel avec des lentilles objectif à faible NA et un matrice de LEDs, reconstruisons par le calcul une image en haute résolution de l'intensité et de la différence de phase de la lumière à travers l'échantillon. Un système d'imagerie FPM, capture n images de basse résolution, où n correspond au nombre de LEDs et ensuite en utilisant des algorithmes de reconstruction nous obtenons une image complète en intensité et en phase.(3)

Mathématiquement, le système d'imagerie avancée de FPM peut être modélisé comme le processus d'imagerie cohérente, comme dans la formule suivante :

$$I_n(x, y) = |(O(x, y) \cdot e^{i(k_{nx}x + k_{ny}y)}) * PSF(x, y)|^2 \quad [2.1]$$

Où $I_n(x, y)$ représente l'image basse résolution obtenue avec la *Light-emitting Diode* (LED) n dans le domaine spatial, $O(x, y)$ représente l'objet complexe dans le domaine spatial, $*$ représente la convolution, $PSF(x, y)$ représente la *Point Spread Function* (PSF) de la pupille dans le domaine spatial. Une image basse résolution est décrite par un objet complexe, qui représente l'image complexe avec l'intensité et la phase, décalée de k_{nx} et de k_{ny} (décalage dû au positionnement du LED) convoluée avec la PSF qui représente les limitations de la pupille dans le domaine spatial.

Dans le système à diffraction limitée, où la résolution du système est déterminée uniquement par NA, nous désignons la PSF comme la transformée de inverse Fourier de la CTF; ainsi, comme nous pouvons le voir dans l'équation 2.1, la CTF est définie par la limite de l'ouverture numérique multipliée par k_o , où $k_o = 2\pi/\lambda$ et λ est la longueur d'onde.

$$\begin{aligned} CTF(k_x, k_y) &= FT\{PSF(x, y)\} \\ CTF(k_x, k_y) &= 1, && \text{if } k_x^2 + k_y^2 < (NA \cdot k_0)^2 \\ &0, && \text{otherwise} \end{aligned}$$

[2.2]

Sur la figure 2, on peut voir le processus détaillé de la fpm. Dans l'étape 1, nous avons l'initialisation de l'image haute résolution comme l'image centrale interpolée basse résolution pour obtenir les mêmes dimensions, et nous avons donc aussi une initialisation du spectre de Fourier. Dans les étapes 2 et 3, l'image d'acquisition basse résolution est transformée dans le domaine des fréquences et remplacée dans le spectre de Fourier pour être reconstruite dans la position correspondant à son vecteur d'onde. Ce processus est effectué pour toutes les n images à faible résolution et répété une seconde fois. À la fin de ce processus, le spectre de Fourier reconstruit est transformé par la transformation inverse de Fourier en une image d'intensité et de phase à haute résolution.

Les méthodes classiques et plus anciennes de reconstruction de phase ont été initialement utilisées comme l'algorithme de Gerchberg-Saxton(4) et l'algorithme de Fienup(5; 6). L'objectif de l'algorithme décrit dans la figure 3 est de trouver une bonne estimation de la phase ϕ , ayant initialement une connaissance de l'image d'intensité ($\sqrt{I_0}$) et de l'intensité de la source.

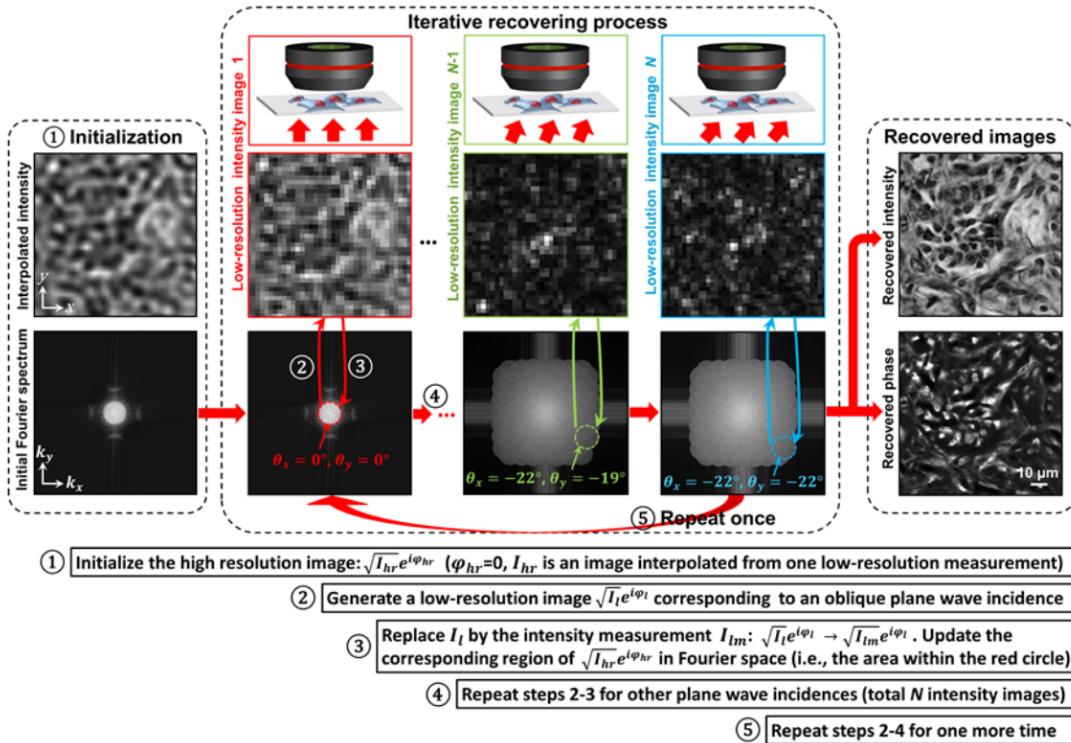


FIGURE 2: Explication du processus de reconstruction par les fpm, selon le principe de la récupération par étapes. Sur le côté gauche, nous avons l'initialisation du processus avec une image basse résolution du led central et sur le côté droit, nous avons l'image reconstruite en intensité et en phase. Source : (2)

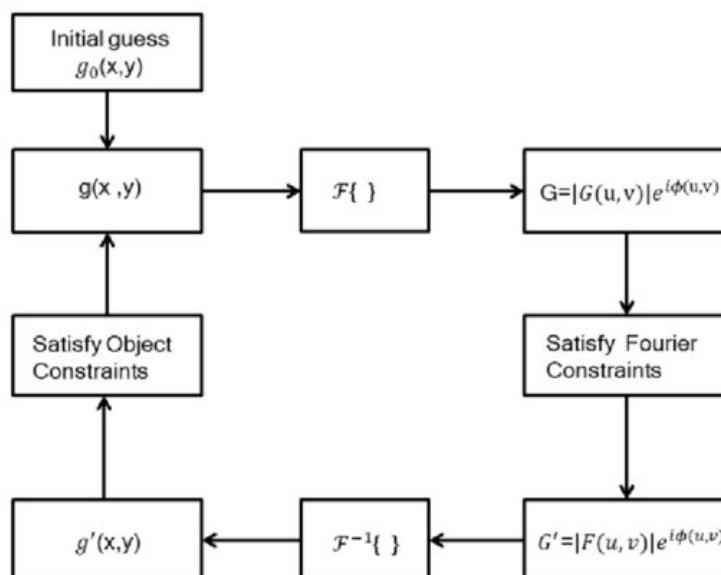


FIGURE 3: Organigramme de l'algorithme interactif de Gerchberg-Saxton. Source : (7)

2.2 RECONSTRUCTION PAR RÉSEAUX NEURONAUX ET APPRENTISSAGE

Des méthodes alternatives ont été développées afin d'améliorer la qualité de la reconstruction de l'image et aussi d'améliorer la vitesse de cette récupération.

Le concept de réseaux neuronaux existe depuis des décennies, mais avant approximativement 2010, ils n'étaient pas vraiment utilisés dans la communauté scientifique. Mais avec l'apparition de l'utilisation des GPU et de la puissance de calcul, la situation a commencé à changer lorsqu'ils ont permis l'utilisation de réseaux plus complexes. Ces réseaux plus complexes sont connus sous le nom de *Deep Learning*. Par conséquent, l'utilisation du *Deep Learning* a eu un impact positif sur plusieurs domaines tels que la reconnaissance d'objets visuels, la reconnaissance vocale et d'autres domaines (8). Il a également provoqué une croissance des applications utilisant l'apprentissage approfondi, et cet impact s'est également produit dans le domaine de la FPM.

Certaines publications utilisent des réseaux de neurones pour optimiser la récupération de phase en fonction de la différence entre les images originales à basse résolution et les images prédites par le réseau de neurones. L'article (9), démontre deux façons différentes d'effectuer la récupération de phase en utilisant les réseaux de neurones et Tensorflow (10).

Les deux modèles sont basés sur la formule mathématique d'un système d'imagerie cohérent avancé. Ces modèles permettent la reconstruction d'une image complexe (intensité et phase) à partir des images d'acquisition d'un système fpm à partir d'un réseau de neurones. Le premier modèle propose un réseau de neurones qui permet la reconstruction de l'amplitude et de la phase en se basant sur le processus d'imagerie avancée de la *Fourier Ptychography* (FP), c'est-à-dire travailler dans le domaine spatial. Le second modèle propose de faire la reconstruction de l'amplitude et de la phase dans le domaine de Fourier, c'est-à-dire de reconstruire l'objet complexe dans le domaine de Fourier. Le fonctionnement de ces deux modèles est détaillé dans la section 3.

Dans l'article (11), l'objectif principal est d'optimiser la disposition des LEDS, grâce à un réseau neuronal convolutif, afin d'obtenir un meilleur résultat dans une classification spécifique. Dans cet algorithme, nous avons donc comme entrée l'ensemble des images avec n illuminations différentes, c'est-à-dire les images échantillonées par le microscope. Nous avons également en entrée l'étiquette de chaque image, et un modèle de classification de ces images préalablement paramétré. Ainsi, à chaque interaction, l'algorithme tente d'optimiser la configuration des LEDs par le biais des erreurs de classification de l'image, de sorte que cet algorithme tente d'obtenir la meilleure configuration de LEDs pour ce domaine de classification.

La différence entre ces deux premiers articles est qu'ils ont des objectifs différents, alors que le premier (9) essaie de reconstruire le modèle FP par le biais d'une CNN, le second (11) essaie d'optimiser la manière de capturer des images pour un certain type de classification.

Dans le contexte de l'optimisation du mode de capture des FPM, nous pouvons mentionner (12). Cette proposition consiste à trouver un modèle de LED qui maximise les performances de reconstruction du système FPM. Pour cela, on utilise une approche de réseau neuronal basée sur la physique, dans laquelle la formule du problème inverse du modèle *forward* est utilisée. Par conséquent, les seuls paramètres à optimiser sont les pondérations de la luminosité de chaque LED et cela permet au réseau d'apprendre avec peu de données. Et comme fonction de perte, on utilise la différence d'amplitude ou de phase entre l'image reconstruite du réseau et l'image originale. Cette méthode permet d'améliorer le temps d'acquisition des images.

3

LES APPROCHES ÉTUDIÉES

Afin de générer un algorithme de reconstruction d'image valide, certaines approches déjà mentionnées dans le chapitre sur l'état de l'art ont été étudiées en détail et sont décrites ci-dessous.

3.1 MODÉLISATION DE LA FPM AVEC LE RÉSEAU DE NEURONES

Nous avons précédemment discuté de deux modèles proposés par (9). Les codes des deux modèles sont fournis en python par (9), mais dans une proposition de simulation de chaque modèle séparément. Comme indiqué dans la section 2, le système d'imagerie avancé par FPM peut être décrit comme dans l'équation 2.1 (9).

Basé sur l'équation 2.1, le premier modèle du (9) a été construit. Pour le fonctionnement de la simulation du premier modèle appelé, *FPM_Simulation_intensityNet* les images de basse résolution sont générées par ce même modèle, en mettant seulement, comme véracité, l'objet complexe comme les images originales, comme le montre la figure 4. Ensuite, ce même modèle de réseau de neurones est utilisé pour effectuer la récupération de phase et d'amplitude des d'images basse résolution simulées, pour cela le point de départ de l'objet complexe est l'image basse résolution de la LED centrale précédemment générée, puis les poids de l'objet complexe sont mis à jour en fonction de la valeur de la fonction de perte qui est la différence entre les images estimées par le réseau et les véritables images basse résolution, comme on peut le voir sur la Figure 5.

Comme nous décrivons le processus d'imagerie avancée dans 2.1, nous pouvons passer cette formule au domaine fréquentiel. Dans le domaine fréquentiel, nous pouvons décrire chaque image basse résolution comme une onde de sortie complexe :

$$FT(I_n(x,y)) = \varphi_n(k_x, k_y) \quad (3.1)$$

$$\varphi_n(k_x, k_y) = \hat{O}(k_x, k_y) \cdot CTF_n(k_x, k_y) \quad (3.2)$$

Où $\hat{O}(k_x, k_y)$ représente l'objet complexe dans le domaine fréquentiel et $CTF_n(k_x, k_y)$ représente le qui représente les limitations de la pupille dans le domaine fréquentiel

Le deuxième modèle a été élaboré sur la base de l'équation 3.2. Pour le fonctionnement de la simulation du second modèle appelé *FPM_Simulation_exitWave*, des images à basse résolution sont générées dans ce code en utilisant la multiplication de la CTF par l'objet complexe comme on peut le voir dans la figure 6, ceci est possible sur la base de l'équation 3.2. Pour entraîner le réseau du second modèle, Figure 7, et obtenir les informations correctes de l'objet complexe, une première hypothèse est faite où l'objet complexe dans le domaine fréquentiel est égal à la transformée de Fourier de l'image basse résolution de la LED centrale. Ensuite, les poids sont mis à jour en fonction de la différence entre les images basse résolution obtenues avec le réseau neuronal du modèle 2 et les images basse résolution de l'exemple.

Le modèle de réseau neuronal 1 de Jiang et al. (2018) - Génération d'images

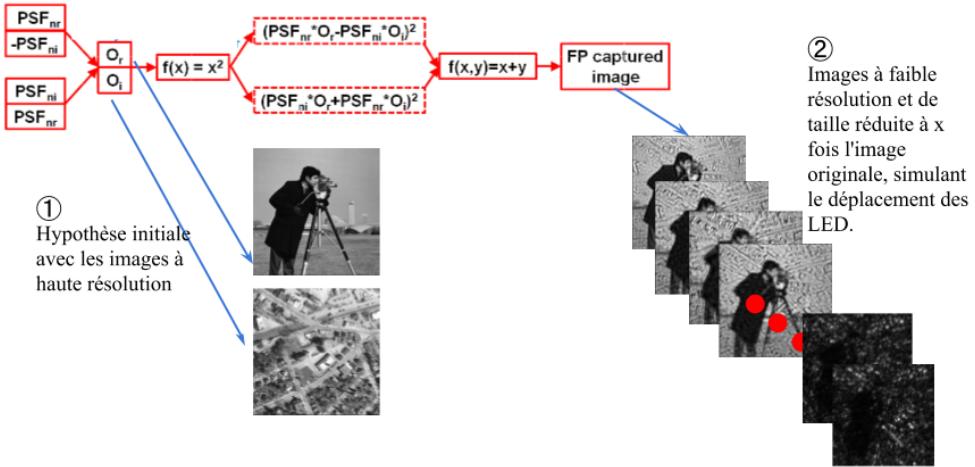


FIGURE 4: Modèle 1 de (9) appelé *FPM_Simulation_intensityNet*, fonctionne comme un simulateur d'acquisition d'images FPM. À l'étape 1, les couches convolutionnelles O_r et O_i sont remplacées par les images haute résolution correspondant à une bonne réponse. Dans l'étape 2, nous avons le résultat de ce réseau qui sont les images de basse résolution estimées par le réseau, simulant ainsi la capture d'un FPM. Adapté de (9).

Les deux modèles proposés par (9) sont disponibles en code utilisant TensorFlow(10). Certains problèmes ont été constatés dans les codes disponibles pour les faire fonctionner comme prévu avec des données réelles, car tous les tests effectués dans les codes disponibles l'ont été uniquement avec des images générées par l'ordinateur. Ainsi, pour que le réseau puisse travailler sur des données réelles, les modifications ont été apportées à la base de (13).

Le modèle de réseau neuronal 1 de Jiang et al. (2018) - Reconstruction de l'amplitude et de la phase

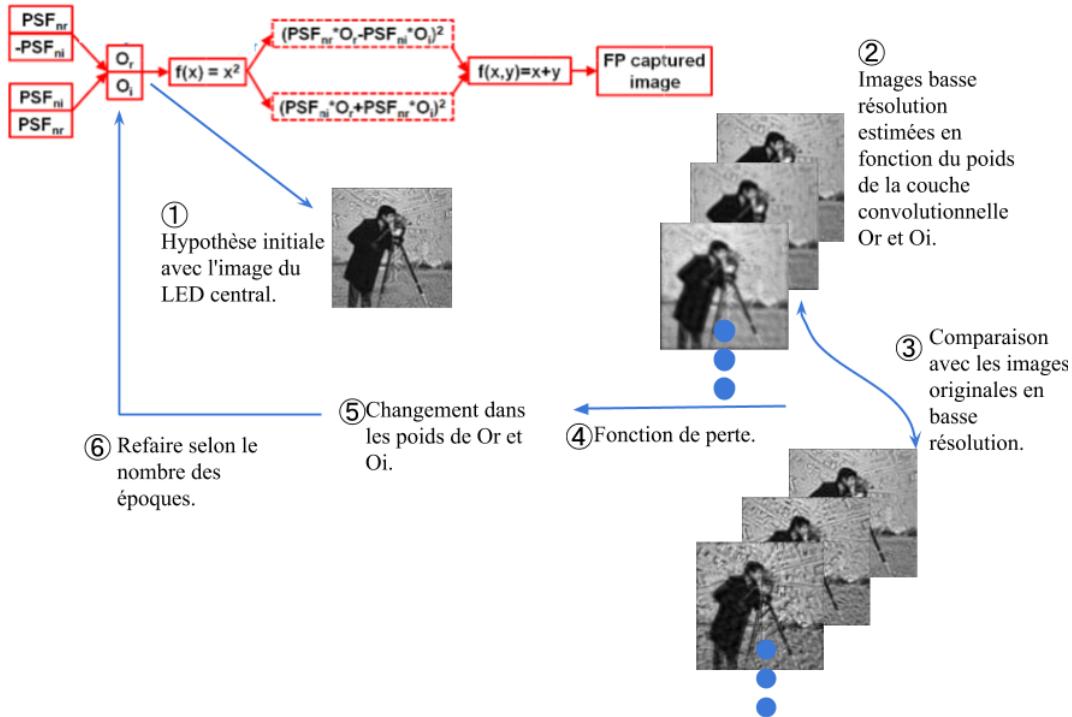


FIGURE 5: Modèle 1 de (9) appelé *FPM_Simulation_intensityNet*, mais avec application pour la reconstruction de l'amplitude et de la phase des images. Dans l'étape 1, l'hypothèse initiale est faite, mais cette fois, l'image à basse résolution de la LED centrale est utilisée. Dans l'étape 2, nous voyons la sortie du réseau qui est l'estimation des images à basse résolution basée sur les valeurs actuelles de la couche convolutionnelle, puis dans l'étape suivante une comparaison est faite entre les images estimées par le réseau et les images originales en basse résolution. La quantification de cette comparaison est effectuée par la fonction de perte, puis, en fonction de la valeur de cette comparaison, les poids de la couche convective O_r et O_i sont modifiés. Ce processus se déroule en fonction du nombre des époques. Adapté de (9)

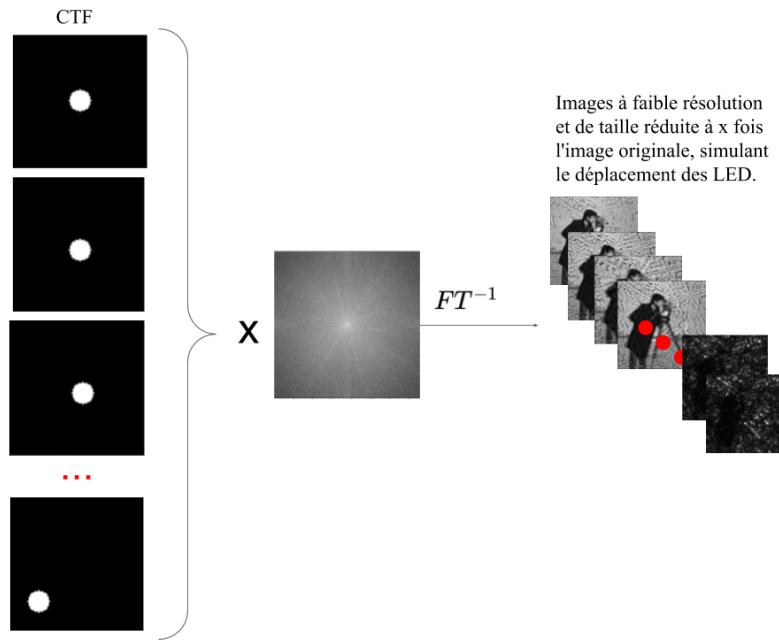


FIGURE 6: Pour créer la simulation de l'image d'acquisition dans le second modèle, la convolution par la PSF est remplacée par la multiplication entre la transformée de Fourier de l'image complexe générée et la CTF qui simule la limitation du microscope. Et puis nous obtenons des images à basse résolution.

Le modèle de réseau neuronal 2 de Jiang et al. (2018) - Reconstruction de l'intensité et de la phase

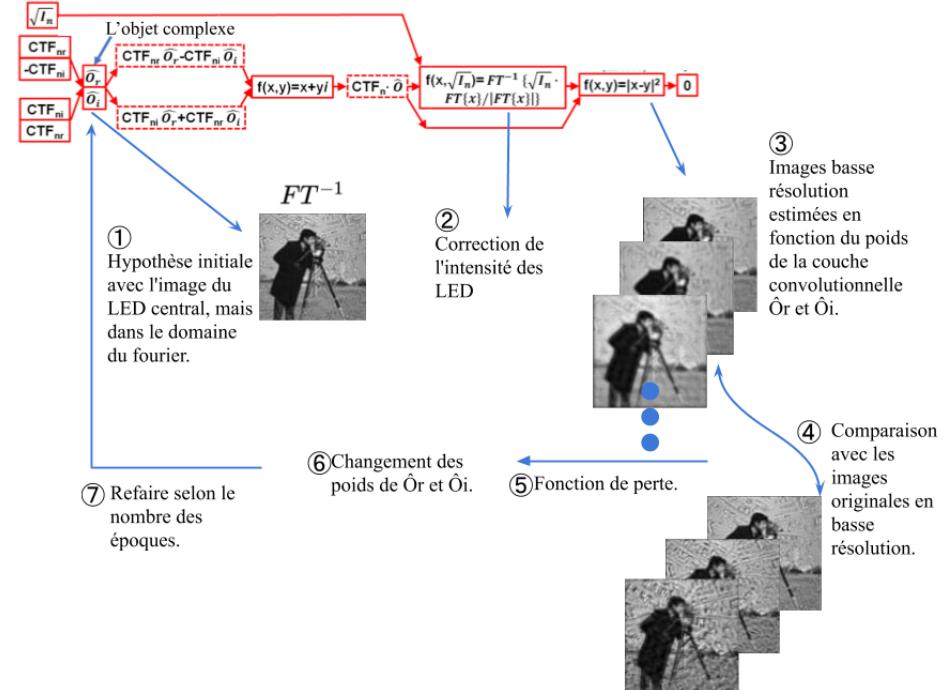


FIGURE 7: Modèle 2 de (9) appelé *FPM_Simulation_ExtiWave*, avec application pour la reconstruction d'amplitude et de phase. Dans la première étape, on effectue une initialisation avec la transformée de Fourier inverse de l'image centrale, dans l'étape 2 avant la sortie du réseau, on a une correction d'intensité et ensuite on a la sortie du réseau qui est comparée aux images d'acquisition à basse résolution dans l'étape 3 et ensuite on a le calcul de la perte et la rétro-propagation des gradients. Adapté de (9)

3.2 MISE EN ŒUVRE

À partir des problèmes identifiés dans les modèles mentionnés dans la section 3.1, des modifications ont été apportées au modèle fourni par (9) et ces modifications étaient basées sur (13). Le principal problème rencontré dans les modèles mentionnés était l'impossibilité de faire une reconstruction avec une taille d'image plus grande que l'image en basse résolution. Le schéma du modèle modifié est disposé dans la Figure 8, les modifications apportées sont les suivantes :

- Ajout de la couche *Roll Layer*, qui fait un décalage du spectre multiplié par CTF_n vers le centre de l'image, car dans la couche précédente chaque CTF_n est positionné en fonction de la position du led n ;
- Ajout de la couche *Crop Layer*, qui fait une coupe centrée sur le spectre de l'image et la mesure de cette coupe est $1/index_downSample$;
- Ajout de la couche *Impose intensity correction* qui corrigera la fluctuation de l'intensité lumineuse sur les différentes LEDs, en utilisant comme entrée l'image d'acquisition à basse résolution décrite dans l'image comme I_n .

Une caractéristique importante de ce modèle d'apprentissage profond est que nous dispensons un pré-entraînement sur l'ensemble des données. Autrement dit, l'apprentissage se fait sur un ensemble de données fixes pour toute l'entraînement et les couches \hat{O}_r et \hat{O}_i sont les couches optimisées avec rétropropagation pour gradient.

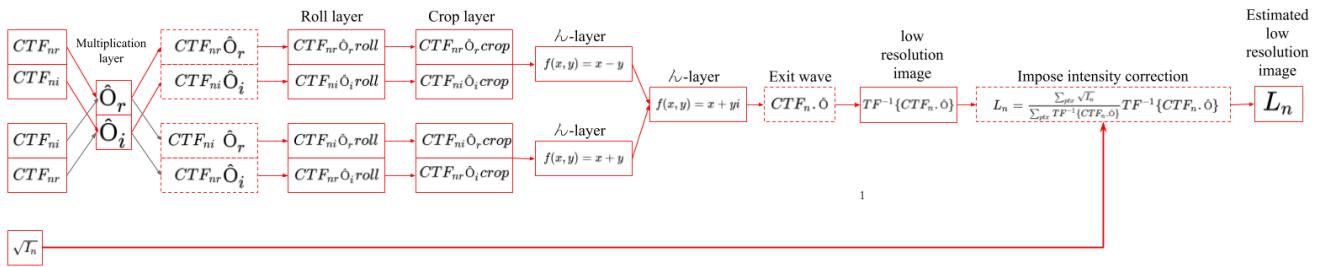


FIGURE 8: Modèle de réseau neuronal pour la reconstruction d'images avec FPM, utilisant la CTF et les images à basse résolution comme entrée, basé à (9)

Nous pouvons décrire le fonctionnement de ce modèle de la manière suivante, dans un premier temps nous faisons une initialisation des poids des couches \hat{O}_r et \hat{O}_i ; cette initialisation est la transformation de Fourier de l'image de la LED centrale redimensionnée aux nouvelles dimensions. Ensuite, nous effectuons la multiplication de l'objet complexe, \hat{O} , avec le CTF_n décalé selon le positionnement de la LED n. Ensuite, nous déplaçons cette multiplication du spectre par le CTF_n vers le centre et nous faisons une coupe de la taille de l'image basse résolution originale, puis la transformée de Fourier inverse pour obtenir l'image basse résolution de synthèse et ainsi corriger les fluctuations de l'intensité lumineuse avec l'image basse résolution d'acquisition et au final nous avons une image basse résolution de synthèse.

L'erreur de notre réseau est définie comme l'erreur moyenne absolue entre l'image basse résolution générée par le réseau et l'image basse résolution d'acquisition, comme on peut le voir dans la formule 3.3, où L_i représente l'image basse résolution générée par le réseau de neurones et I_i représente l'image basse résolution d'acquisition..

$$loss = \left(\frac{1}{n} \right) \sum_{i=1}^n \left| L_i - \sqrt{I_i} \right| \quad (3.3)$$

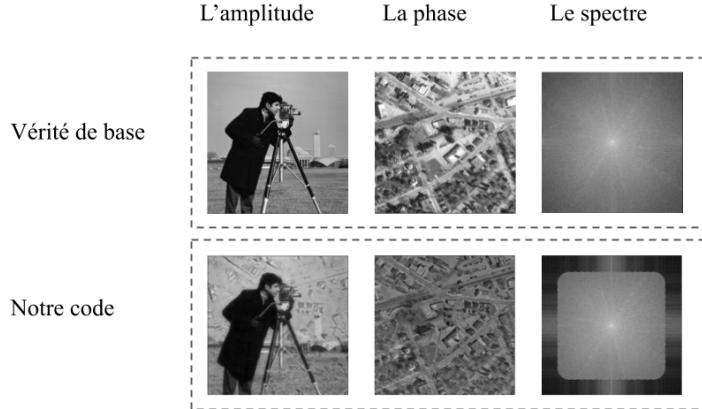


FIGURE 9: Comparaison entre le résultat de la reconstruction du réseau neuronal par FPM en haute résolution et les images d'intensité et de phase originales en haute résolution.

Des tests ont été effectués avec des images de synthèse à basse résolution que nous avons créées pour valider le comportement du réseau neuronal dans la reconstruction d'images FPM. Comme on peut le voir sur la figure 9, nous avons pu reconstruire l'image avec une bonne qualité. Nous avons ensuite effectué le même test avec deux ensembles différents d'images d'acquisition, le *USAF resolution target* et le *blood smear* fournis par (14), dans le cas de l'ensemble de données *USAF resolution target* nous avons obtenu un bon résultat car la description de la pupille dans cet ensemble est proche du binaire. Mais dans l'ensemble de données *blood smear* nous avons obtenu une reconstruction de faible qualité, donc nous avons modifié notre modèle pour effectuer la reconstruction de la pupille afin d'obtenir une image de meilleure qualité.

	Récupération de l'intensité	Récupération des phases	Description de la pupille
Méthode de Zheng MatLab			
Notre Code			

FIGURE 10: Comparaison entre le résultat de la reconstruction obtenue avec le code matlab fourni par Zheng et le résultat du réseau neuronal modifié.

semble de données *USAF resolution target* nous avons obtenu un bon résultat car la description de la pupille dans cet ensemble est proche du binaire. Mais dans l'ensemble de données *blood smear* nous avons obtenu une reconstruction de faible qualité, donc nous avons modifié notre modèle pour effectuer la reconstruction de la pupille afin d'obtenir une image de meilleure qualité.

	Récupération de l'intensité	Récupération des phases	Description de la pupille
Méthode de Zheng MatLab			
Notre code			

FIGURE 11: Comparaison entre le résultat de la reconstruction obtenue avec le code matlab fourni par Zheng et le résultat du réseau neuronal modifié.

3.3 MODÈLE DE RÉSEAU NEURONAL POUR LA RECONSTRUCTION D'IMAGES AVEC FPM ET RECONSTRUCTION DE LA PUPILLE

Comme nous l'avons mentionné dans le modèle précédent, comme la reconstruction de la pupille n'a pas été effectuée, les tests sur l'ensemble des données n'ont pas bien fonctionné, ce qui démontre l'importance de la reconstruction de la pupille pour une reconstruction d'image FPM de qualité. Ce phénomène est dû au fait que nous avons des aberrations optiques dans le système d'imagerie, et ces aberrations varient en fonction de la complexité de la lentille utilisée dans le microscope, donc la correction de ces aberrations permet la reconstruction des images par FPM avec des lentilles aberrantes (15). Nous avons ensuite apporté des modifications au modèle précédent pour la correction de ces aberrations, comme le montre la figure 21.

L'un des principaux changements dans ce modèle est la description de la pupille, auparavant nous décrivions la pupille binaire, comme dans l'équation 2.1. Et maintenant, nous commençons à décrire la pupille comme une combinaison linéaire des polynômes de Zernike comme on peut le voir dans l'équation 3.4, comme décrit dans le livre (3) nous avons ajouté à la CTF un terme de phase.

$$P = CTF \cdot \exp(j \cdot Z_{comb}) \quad (3.4)$$

Dans l'équation 3.4, P représente la pupille complexe et le terme Z_{comb} est une combinaison linéaire de polynômes de Zernike, pour plus de détails sur les polynômes Zernike dans la section 6.

Nous pouvons décrire le flux de travail de ce réseau de neurones comme suit : dans les entrées, nous fournissons 10 premiers polynômes de type Zernike, où $Z_1 = Z_0^0$, $Z_1 = Z_{-1}^1$ et ainsi de suite. Nous fournissons également en entrée la CTF mais avec une différence par rapport au modèle précédent, car cette CTF est centrée au point (0,0), c'est-à-dire qu'elle n'est pas déplacée en fonction du positionnement de la LED. Nous avons également comme entrées les vecteurs d'onde k_x et k_y pour les n différentes mesures d'intensité et les images basse résolution de acquisition.

Dans ce réseau, les couches de l'objet complexe \hat{O}_r et \hat{O}_i seront entraînées par rétropropagation de gradient. Et aussi les poids de la couche de combinaison linéaire des polynômes de Zernike seront

entraînés par la rétropropagation du gradient.

Par conséquent, les couches de l'objet complexe et la combinaison linéaire du polynôme de Zernike sont initialisées, l'objet complexe est initialisé comme décrit dans le modèle précédent. Et les poids des couches du polynôme de combinaison linéaire de Zernike sont tous initialisés avec des zéros. Après l'initialisation, le résultat de la combinaison linéaire est utilisé pour définir la pupille comme dans l'équation 3.4, puis la pupille est séparée en deux couches : l'une correspondant à sa partie réelle et l'autre à sa partie imaginaire. Sur le côté de l'objet complexe après l'initialisation, nous déplaçons cet objet par rapport au vecteur d'onde, pour chaque mesure d'intensité différente. Nous effectuons ensuite la multiplication entre l'objet complexe et la pupille complexe. Dans la couche suivante, le résultat de cette multiplication est découpé en fonction de la dimension de l'image basse résolution, puis la transformation inverse est effectuée pour obtenir l'image basse résolution générée par le réseau. Et comme dans le modèle précédent, une correction d'intensité est effectuée dans la dernière couche.

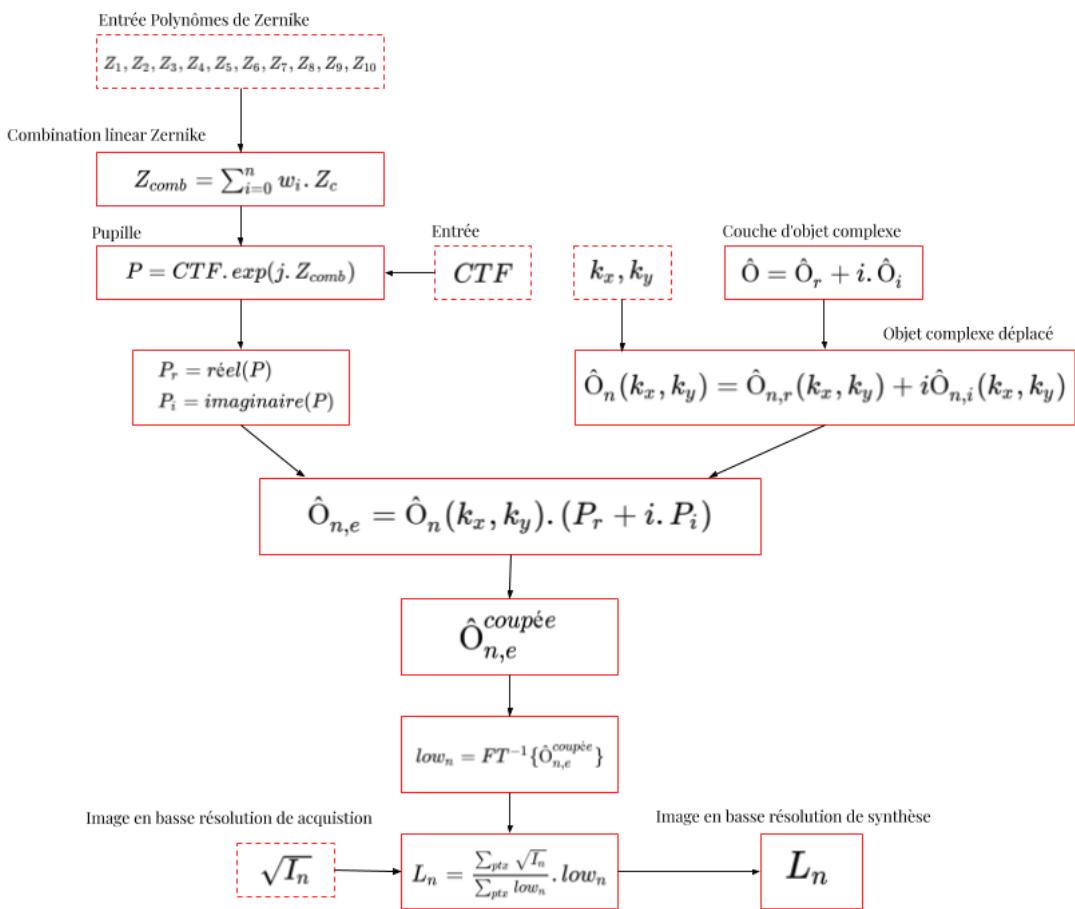


FIGURE 12: Modèle de réseau neuronal pour la reconstruction d'images FPM et la reconstruction de la pupille.

L'erreur de notre réseau est définie avec la valeur absolue moyenne comme dans le réseau précédent, et comme dans l'équation 3.3.

Lorsque nous avons effectué le test avec le modèle précédent sur l'ensemble des données *blood-smear* nous avons identifié la dégradation de la reconstruction en ne réalisant pas la reconstruction de

la pupille. Par conséquent, en refaisant les tests, nous obtenons de bons résultats comme le montrent les figures 13 et 14, qui montrent qu'avec le modèle actuel, nous pouvons faire une reconstruction de qualité même sur des images capturées par des élèves aberrants.

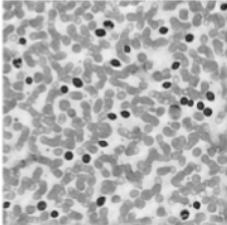
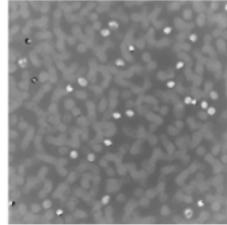
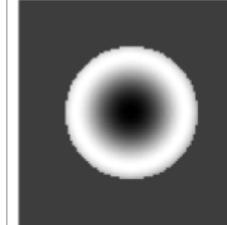
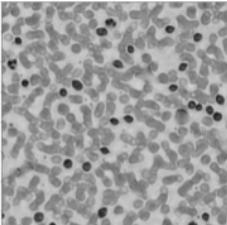
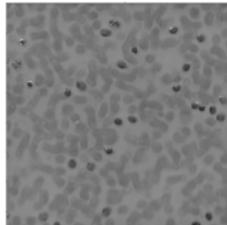
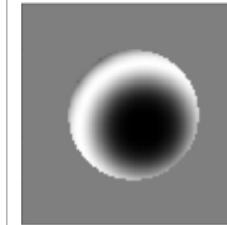
	Récupération de l'intensité	Récupération des phases	Description de la pupille
Méthode de Zheng MatLab			
Reconstruction de l'image en utilisant le polynôme de Zernike comme description de l'aberration de la pupille.			

FIGURE 13: Résultat du modèle de réseau neuronal pour la reconstruction d'images FPM et la reconstruction de la pupille avec l'ensemble des images *bloodsmear*

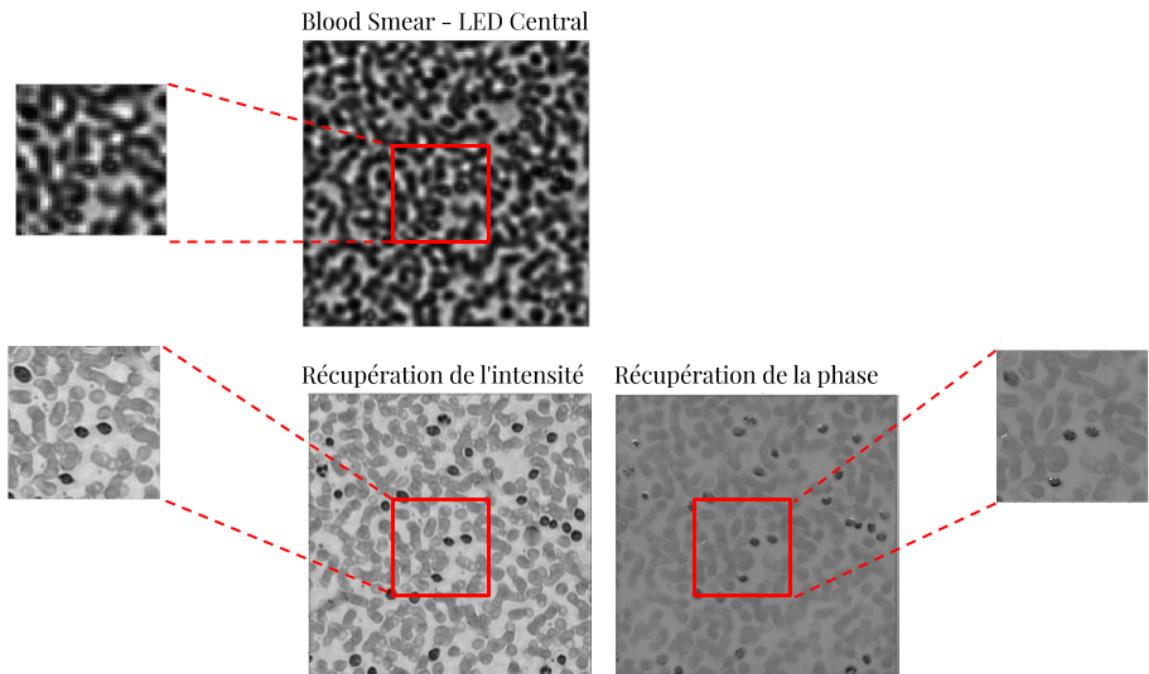


FIGURE 14: Différence entre l'image centrale *bloodsmear* sans fpm et l'image reconstruite avec fpm.

3.4 ENSEMBLE DES DONNÉS

Notre ensemble de données est composé de 35 images capturées par un microscope classique avec différentes intensités, c'est-à-dire différentes positions de LED. Où les échantillons de cellules sanguines ont été capturés. Ils sont répartis comme suit avec une LED centrale et 3 cercles contenant respectivement 6, 12 et 16 leds, comme on peut le voir sur la Figure 15. Les images fournies ont un NA de 0.75μ , un grossissement optique égal à 20 et des dimensions de 2456 par 2054 pixels, séparés en trois canaux (Rouge, Vert et Bleu). Ces données sont divisées en quatre patients avec des quantités d'échantillons différentes, comme on peut le voir dans le tableau 1.

Dans les travaux actuels, nous nous concentrons sur l'application des méthodes sur le patient CAT01, car il est infecté par de gros parasites.

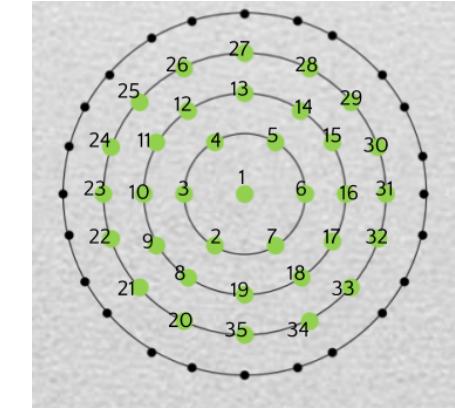


FIGURE 15: Description du positionnement des LEDs

Patient	Description	Nombre d'images	Nombre de cellules
CAT01	patient infecté par des gros parasites	10	13743
KPJ0	patient infecté avec des petits parasites.	40	54359
DA	patient sain avec beaucoup de plaquettes.	30	32149
LE	patient sain avec un taux de plaquettes normal.	30	32094

TABLE 1: Description des patients dans l'ensemble de données et des quantités correspondantes d'échantillons et de cellules.

3.4.1 Estimation du positionnement des LEDs

Dans notre base de données, nous n'avons pas la position exacte des LED, mais seulement des informations sur leur format. Le positionnement des LED est une information importante, comme mentionné en (15). L'imprécision du positionnement des LED, principalement dans les matrices réalisées sur les mesures, peut entraîner une dégradation de la reconstruction.

Comme nous n'avions pas les positions décrites dans un document, nous avons initialisé les positions comme le centre a mené à la position (0.0), et pour le cercle des leds, nous avons divisé l'angle de 360 degrés par le nombre de led dans le cercle et nous avons attribué un rayon. Par exemple, dans le premier cercle où nous avons 6 leds, chaque led a été positionnée avec une différence de 60 degrés et un rayon a été attribué à ce positionnement, pour le premier cercle initialement défini avec 11mm. Bien que nous ayons fait ce premier pas, nous avons déjà vu des résultats significatifs en faisant la reconstruction avec le modèle de la section 3.3.

A la recherche de références sur le sujet, on trouve en (16) qui fait l'optimisation du positionnement en recherchant la circonférence de CTF dans le spectre de Fourier de l'image en basse résolution. Le code qu'ils utilisent dans cet article est disponible en MatLab et nous avons essayé de l'utiliser avec nos données mais nous n'avons pas pu obtenir de bonnes améliorations. Mais bien que nous ne puissions pas utiliser l'algorithme fourni par (16) l'article parle de la façon d'améliorer la visualisation du spectre

d'image pour identifier les positions de la CTF. Les améliorations sont l'utilisation d'un filtre gaussien avec $\sigma = 1$ et aussi la division de l'image du spectre par la moyenne des points de l'image du spectre, avec ces améliorations nous pouvons visualiser un peu mieux les CTF dans le spectre et commencer un étalonnage à la main, comme on peut le voir sur la figure 16 une tentative. Cependant, comme il est possible de le voir dans la figure 17 sur certaines LEDs, cette visualisation est difficile, ce qui rend complexe la définition du positionnement à la main.

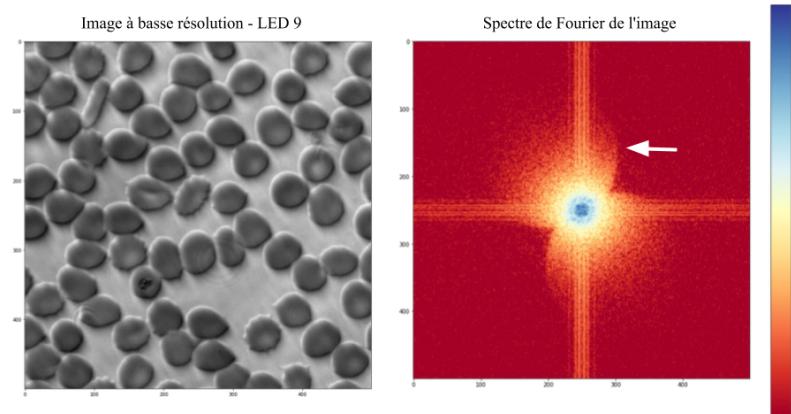


FIGURE 16: Extrait de l'image de la LED 9 et de sa transformée de Fourier, montrant comment il est possible de visualiser le limite circulaire de la CTF dans le spectro de l'image.

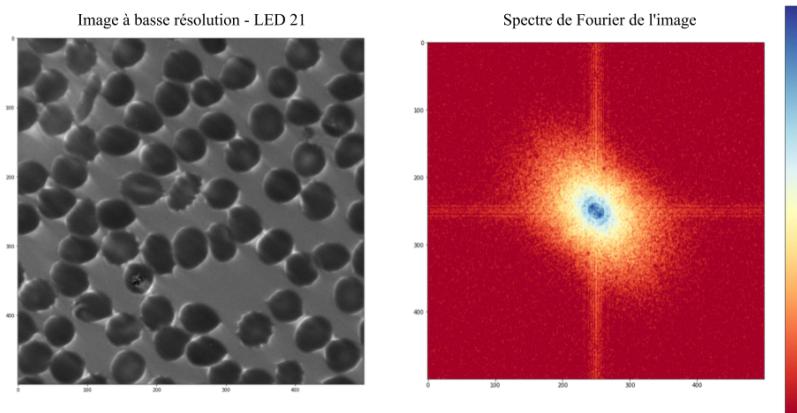


FIGURE 17: Extrait de l'image de la LED 21 et de sa transformée de Fourier.

Nous avons commencé une tentative d'utiliser l'algorithme génétique pour effectuer l'optimisation de chaque LED séparément, en utilisant comme fonction de fitness le résultat de la fonction de perte du réseau neuronal du modèle de reconstruction d'image FPM.

Le résultat de l'utilisation de l'algorithme génétique a été bon pour certaines leds et pas pour d'autres. Comme nous n'avions pas beaucoup de temps, nous avons utilisé les résultats qui ont été améliorés, ces résultats améliorent notre reconstruction. Dans cette figure, nous avons visualisé les courbes d'apprentissage pour les différentes tentatives d'optimisation que nous avons faites et nous pouvons voir que le résultat avec l'algorithme génétique était prometteur. Nous avons donc utilisé cette optimisation du positionnement avec notre contribution pour former la méthode finale.

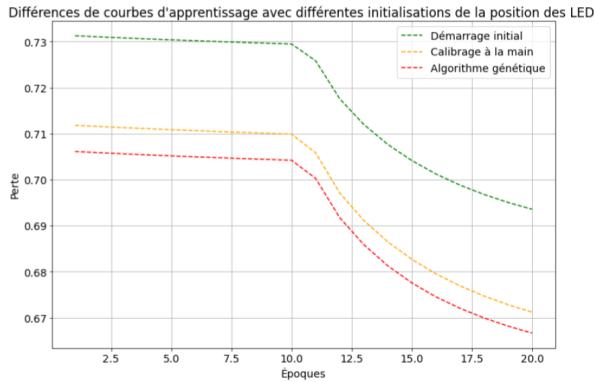


FIGURE 18: Courbe montrant l'impact sur le positionnement des LED dans la reconstruction d'images par FPM de 84x84 pixels.

3.4.2 Atténuation du bruit sur imagettes

Lorsque nous avons commencé les premières tentatives de reconstruction avec les images des cellules, malgré les améliorations sur la position des LEDs dans l'image, il était possible d'observer l'apparition de hautes fréquences, montrant clairement un bruit dans les images reconstruites en intensité et en phase. En effectuant des recherches, nous avons trouvé des études qui démontrent la dégradation de la reconstruction d'une image par FPM lorsque nous avons des images bruitées, nous pouvons citer (17). Face à ce problème, nous avons décidé d'appliquer la fonction openCV appelée *fastNIMeansDenoising* qui provient de l'article (18) et la méthode appelée *Non-Local Means Denoising*, qui fonctionne de la manière suivante : à partir de petits échantillons (fenêtres de dimensions déterminées) similaires dans l'image, on obtient la moyenne du bruit. Il est important de remarquer que le débruitage a été appliqué aux images de basse résolution.

Ainsi, sur la figure 19, nous pouvons voir la différence entre une reconstruction sans suppression du bruit et une reconstruction avec suppression du bruit. Dans le cercle vert au-dessus des images, nous pouvons voir que dans le fond de l'image sans suppression du bruit, nous avons de petits points alors que dans l'autre image, nous ne voyons pas cela. Une observation importante est l'impact sur les images de phase car dans l'exemple, nous avons une image infectée, et nous voyons que la région parasite après le débruitage a une meilleure vue des petits cristaux.

Dans la figure 20, nous effectuons une analyse de l'impact du débruitage sur la valeur de l'erreur sur la courbe d'apprentissage, et les courbes d'apprentissage confirment ce qui est visible dans la figure 19. Par conséquent, dans ce cas où nous avons travaillé avec de petites images, l'utilisation de la suppression du bruit était nécessaire pour améliorer les résultats.

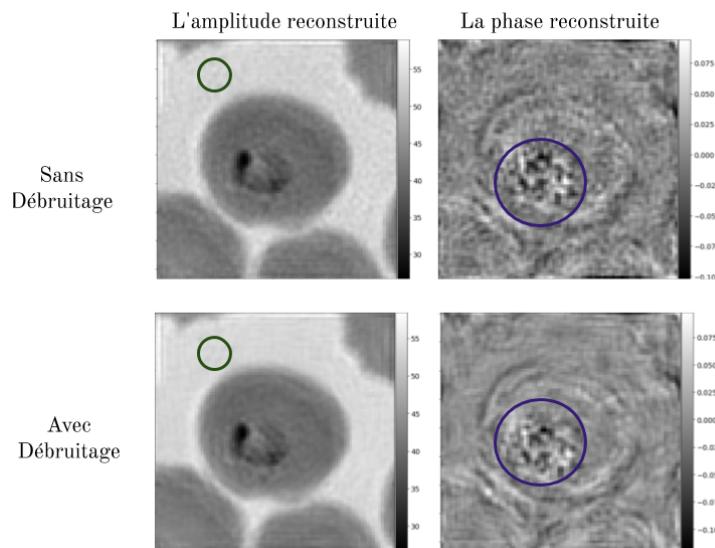


FIGURE 19: Différence entre la reconstruction d'une cellule sans atténuation du bruit et avec atténuation du bruit

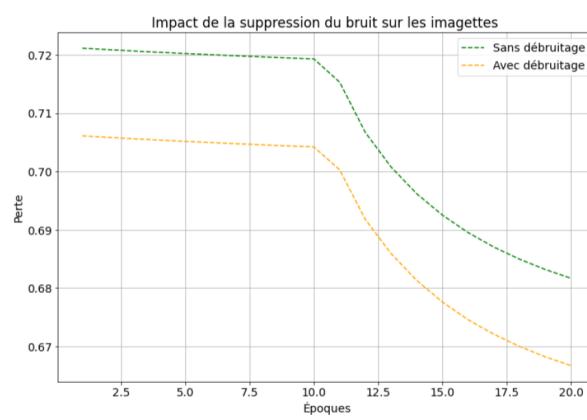


FIGURE 20: Courbe d'apprentissage d'une reconstruction d'une cellule sans atténuation du bruit et avec atténuation du bruit

3.5 MÉTHODE FINALE

Par conséquent, comme méthode finale pour la classification des cellules, nous avons décidé de faire la segmentation des échantillons en utilisant le code développé par l'étudiant Nicolas Gourgue, cette segmentation sera faite et des imagettes de 84x84 pixels seront créées pour chacune des 35 leds différentes. Ensuite, ces cellules seront reconstruites une par une à l'aide du modèle de réseau neuronal qui effectue la reconstruction du FPM et de la pupille. Et ces résultats de reconstruction seront utilisés comme entrée pour le classificateur ResNet. Et ensuite les résultats de la classification seront évalués, ces évaluations seront faites dans trois cas : le premier utilisera comme entrée du classificateur les cellules segmentées seulement de la led centrale sans FPM, le deuxième utilisera comme entrée du classificateur les cellules segmentées et reconstruites par FPM en intensité et le troisième cas utilisera comme entrée du classificateur les cellules segmentées et reconstruites par FPM en intensité et en phase.

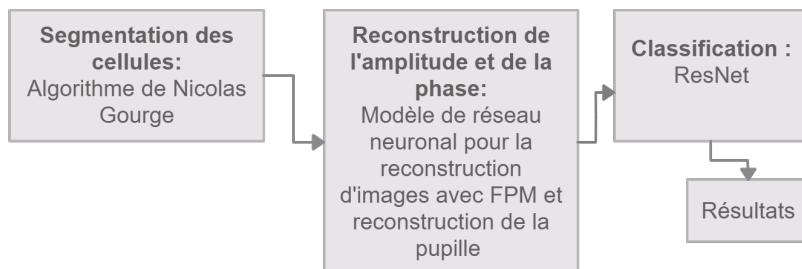


FIGURE 21: Organigramme de la méthode finale choisie pour effectuer les évaluations.

3.5.1 Segmentation

Pour effectuer la segmentation cellulaire, nous avons utilisé la segmentation déjà réalisée par l'étudiant Nicolas Gourgue (19), qui est une méthode classique de segmentation de la morphologie mathématique. Nous avons donc pris l'étiquetage déjà réalisé par Nicolas Gourgue et l'avons appliqué aux patients, puis nous avons divisé les échantillons de sang en images cellule par cellule. Bien que cette étape était prête, il a fallu la refaire car les images sauvegardées ont été découpées mais pour faire la reconstruction par FPM nous avions besoin de la miniature de la cellule avec le fond.

3.5.2 Augmentation des Donnés

Nous avons procédé à l'augmentation des données car nous avions un grand déséquilibre entre les cellules saines et les cellules infectées, et ce déséquilibre pouvait compromettre l'apprentissage du classificateur. Nous avons fait une augmentation du type de rotation avec une gamme de 30 degrés, des rotations verticales et horizontales et un changement de luminosité avec une gamme de 0,2 à 1,0. Cette augmentation a été faite sur les images reconstruites et les images du led central où nous avons assuré que les changements étaient faits de manière égale sur tous les ensembles.

3.5.3 Classification

Pour classer les cellules, nous pourrions créer un nouveau réseau d'apprentissage profond ou utiliser l'apprentissage par transfert, en partant du principe que nous avons plusieurs réseaux pré-entraînés

pour la classification des images et que ces réseaux sont entraînés avec des milliers d'images. Nous avons suivi le choix d'utiliser l'apprentissage par transfert. En choisissant la réseau neurale pré-entraînée, nous avons choisi une Res-Net 152 (20) parce que dans le travail précédent effectué par l'étudiant Nicolas Gourgue, il a fait des comparaisons entre différents types de Res-Net pour effectuer la classification des cellules infectées par le parasite de la malaria et la moustiquaire avec le meilleur résultat était la Res-Net 152. Nous pouvons également souligner le choix du Res-Net car c'est un réseau de faible complexité temporelle par rapport à d'autres réseaux et avec un bon résultat de classification, c'est aussi un réseau entraîné à extraire des caractéristiques d'une image et déjà pré entraîné pour plus de 1000 classes, le réseau a donc la capacité de généraliser et d'extraire des caractéristiques de chaque classe. De plus, le réseau sélectionné est déjà pré-entraîné pour la base de données ImageNet (21), donc notre image d'entrée doit être en dimensions (84,84,3), c'est-à-dire trois canaux de couleur. Par conséquent, comme nous voulons utiliser les poids du réseau préformé, nous devons maintenir la restriction des canaux. Avec les résultats de l'étudiant Nicolas Gourgue, nous avons décidé de travailler uniquement sur le canal vert des images fournies pour avoir montré une meilleure performance dans le taux de faux négatifs.

En ce qui concerne la distribution des données, nous l'avons divisée en trois ensembles : apprentissage, validation et test. Nos données sont réparties en 64% apprentissages, 16% validations et 20% tests.

4

RÉSULTATS

Dans ce chapitre, nous avons mis en œuvre la méthode finale définie dans la section 3.5, nous montrerons donc les résultats de ces méthodes. D'abord nous avons appliqué la segmentation à nouveau pour chaque échantillon de sang uniquement dans le canal vert et ensuite nous avons générée des images de dimensions 84x84. Ces images ont ensuite été reconstruites par le FPM, quelques exemples de reconstruction sont visibles sur l'image 22. Où nous avons l'image de la led centrale, c'est-à-dire la cellule sans reconstruction et ensuite nous avons le résultat de la reconstruction en FPM, avec les images d'intensité et de phase et aussi le spectre de l'image reconstruite. Ce que nous pouvons obtenir, c'est une amélioration de la résolution des images et surtout des informations de phase que nous obtenons et qui permet de contraster les cristaux d'hémozoïne parasites dans les cellules infectées, il est possible de visualiser de petits points noirs et blancs dans la région parasitaire. Alors que dans la phase des cellules saines, il est possible d'observer la non-apparition de ces points.

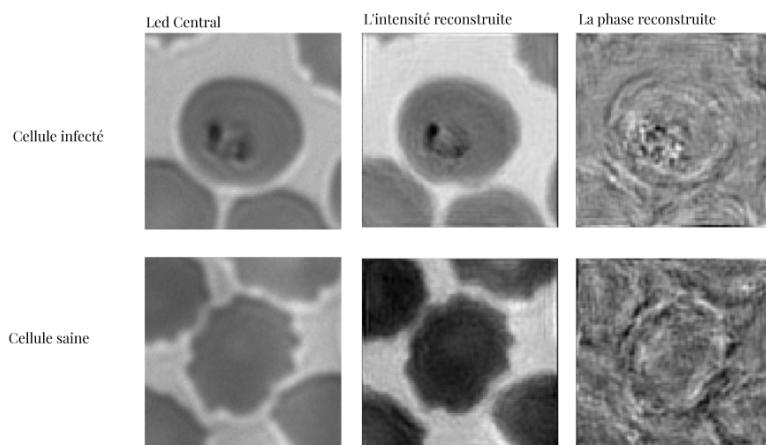


FIGURE 22: Exemple de reconstruction FPM d'une cellule infectée et d'une cellule saine du patient CAT01.

Nous avons donc fait la reconstruction pour le patient CAT01, parce qu'il avait des parasites plus gros et aussi un plus petit nombre de cellules pour faire les premiers tests et ensuite faire la même chose sur les autres patients. Comme nous avions un déséquilibre dans le nombre de cellules infectées et saines, nous avons effectué une augmentation des données sur les cellules infectées, donc avant nous avions un total de 465 cellules infectées et 13278 cellules saines. Et avec l'augmentation des données, nous avons obtenu un total de 13485 cellules infectées.

Une fois la reconstruction effectuée, nous utilisons les images reconstruites comme entrée du classificateur. Comme nous l'avons déjà mentionné, nous ne pouvons pas diminuer le nombre de canaux dans le classificateur Res-Net 152, nous avons donc fait des tests avec trois cas : dans le premier cas, nous avons utilisé l'image centrale des leds, image sans reconstruction, répétée dans les trois canaux de couleur,

dans le deuxième cas, nous avons utilisé uniquement l'image reconstruite en intensité et ensuite nous avons répété cette même image dans les trois canaux et le troisième cas dans lequel nous avons utilisé l'image reconstruite en intensité et en phase, l'image en intensité dans le canal rouge, l'image en phase dans le canal vert et une image constante avec une valeur nulle dans le canal bleu.

Dans la formation avec classificateur, nous utilisons la configuration suivante dans les trois cas : 300 époques, 64 comme taille du batch , un *dropout* de 0,7. En analysant la courbe de accuracy de l'entraînement faite avec la LED centrale (Figure 23) par rapport aux autres cas au départ, nous constatons un écart constant entre les valeurs de accuracy de l'apprentissage et de la validation; nous observons également que la convergence se produit au départ et même en ayant une valeur de *dropout* élevée, alors que dans la courbe de perte, nous avons une instabilité dans la courbe d'ensemble de la validation qui se poursuit tout au long de la formation.

En revanche, les courbes du cas d'entraînement avec l'image reconstruite en intensité (Figure 24) la courbe de accuracy de validation et d'apprentissage sont très proches, et se stabilisent plus rapidement que dans le cas précédent. Dans le cas de l'entraînement avec les images reconstruites en intensité et en phase (Figure 25), nous avons des courbes de accuracy et de perte très stables, en plus d'une convergence plus rapide. Nous pouvons alors affirmer que le cas des images de reconstruction d'intensité et de phase nous apporte une plus grande stabilité pendant l'entraînement.

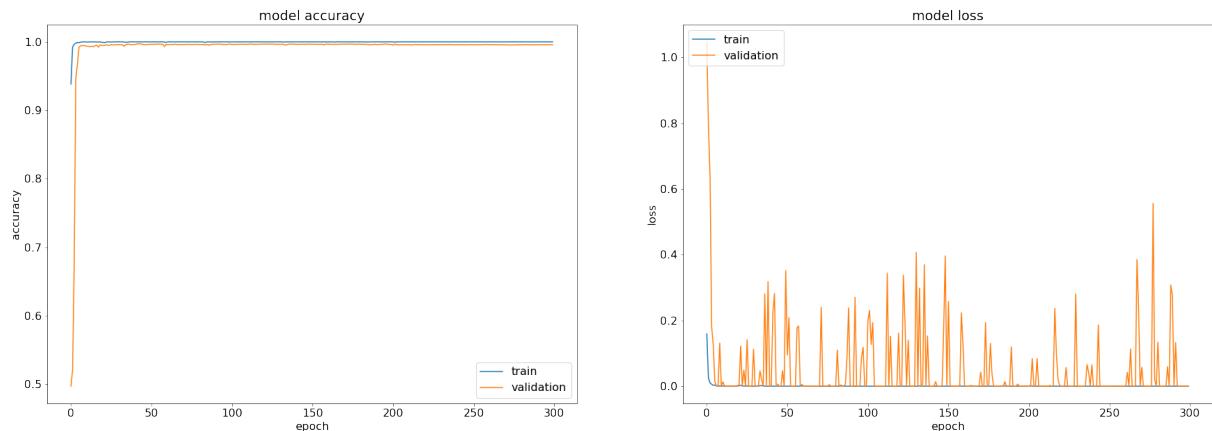


FIGURE 23: Courbe de précision et perte de classification avec les images du led central.

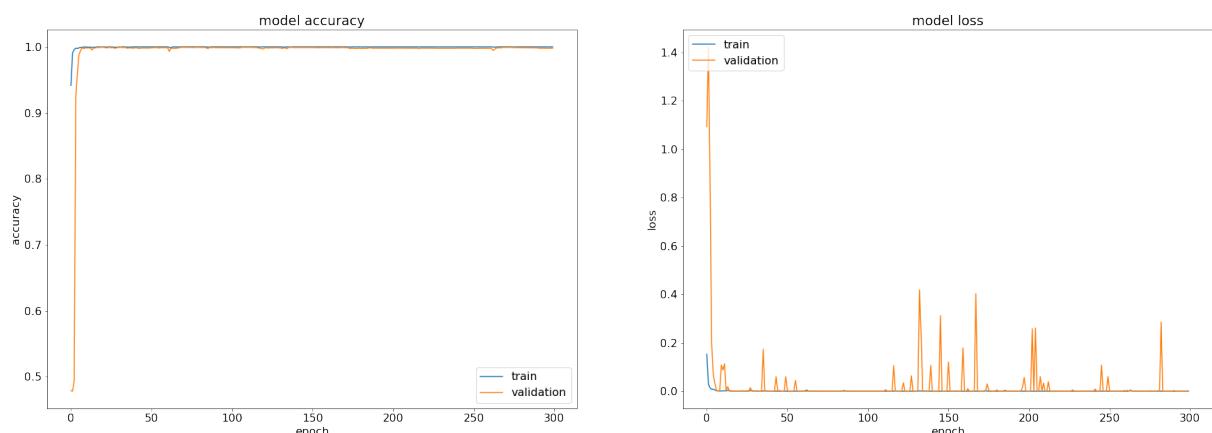


FIGURE 24: Courbe de précision et perte de classification avec les images reconstruites par FPM et utilisant seulement l'intensité.

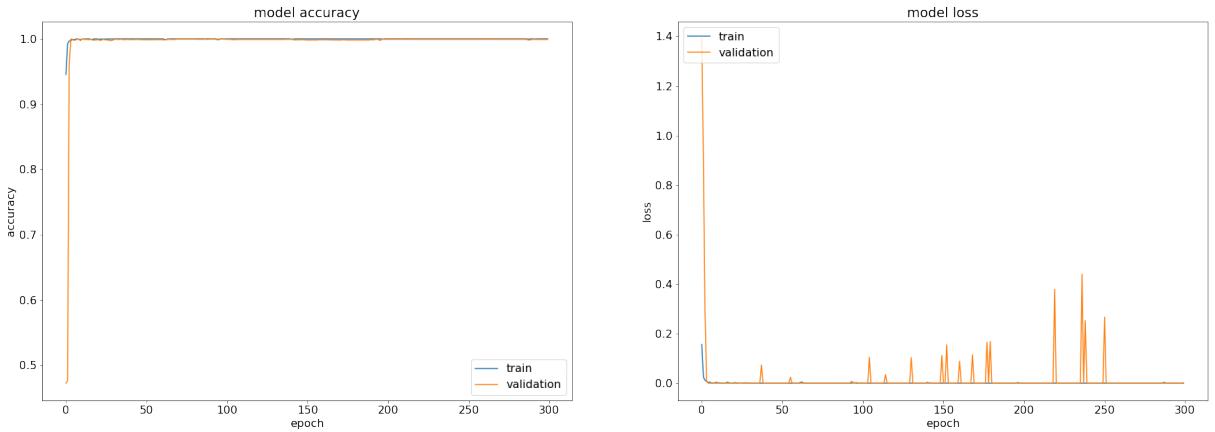


FIGURE 25: Courbe de précision et perte de classification avec les images reconstruites par FPM et utilisant l'intensité et phase.

Cas	Vrai négatif	Faux négatif	Vrai positif	Faux positif	Accuracy	Perte
LED central	99,36%	0,64%	99,89%	0,11%	99.62%	0.3469
FPM Intensité	98,56%	1,44%	99,87%	0,13%	99.19%	0.0346
FPM Intensité + Phase	99,55%	0,45%	99,92%	0,08%	99.72%	0.0

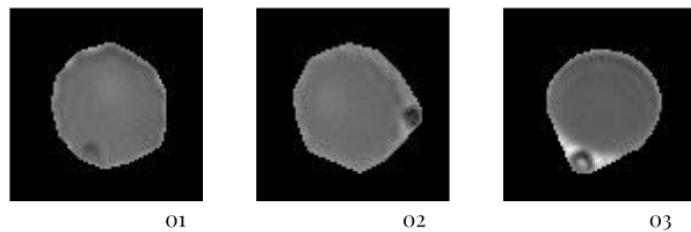
TABLE 2: Résultats des matrices de confusion, de précision et de perte pour chacun des cas testés.

Le tableau 2 montre le résultat de la matrice de confusion de chaque cas ainsi que sa valeur moyenne d'accuracy et sa valeur de perte. Ainsi, le meilleur résultat a été obtenu avec le cas FPM intensité+phase car nous avons une faible valeur de faux négatifs et aussi de faux positifs par rapport aux autres cas, une autre observation importante est la valeur de perte égale à zéro. Alors que dans les autres cas, nous avons une valeur de perte différente de zéro, dans le cas de l'intensité du FPM, nous avons la pire valeur d'acuité, tandis que la valeur de perte est plus stable que dans le cas du LED central.

Après l'analyse des courbes d'apprentissage, nous effectuons une analyse des erreurs produites dans les deux cas les plus performants, c'est-à-dire le cas intensité+phase FPM et le cas LED Central. Dans la figure 26, nous pouvons analyser le cas de la LED centrale, les faux négatifs sont principalement les cas où les parasites sont très proches des bords des images, mais lorsque nous regardons les faux positifs, les images 05 et 06 semblent de vrais positifs tout en proposant que dans nos données nous pouvons avoir un problème d'étiquetage. Alors que l'image 07 ressemble vraiment à un faux positif.

Sur la figure 27, nous pouvons voir les erreurs pour le cas FPM intensité+phase, dans les cas de faux négatifs, nous pouvons voir dans la cellule 01 une erreur due au fait que le parasite se trouve près du bord de la cellule comme cela s'est produit dans le cas de la LED centrale. Dans la cellule 02, nous pouvons voir qu'il semble être un vrai négatif car nous n'avons pas de cristaux visibles dans l'image de phase. Et dans la cellule numéro 03, on peut voir le cas où la cellule parasite se trouve au bord de l'image, difficile à identifier le réseau. Lorsque nous observons les cas de faux positifs, nous pouvons voir dans l'image de phase des deux petits cristaux ce qui nous fait déduire que ces cellules sont vraiment positives et que nous avons probablement une erreur d'étiquetage dans notre ensemble de données.

LED CENTRAL - Faux négatif



LED CENTRAL - Faux positif

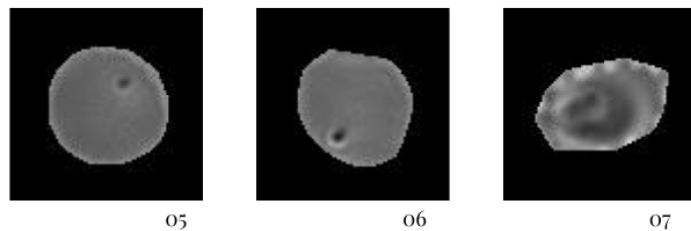
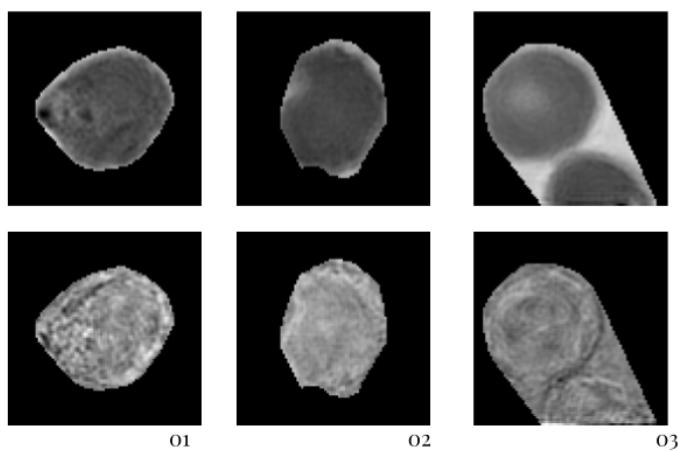


FIGURE 26: Exemple de faux négatifs et faux positifs identifiés par le réseau pour l'entrée comme images de la led centrale sans reconstruction FPM.

FPM INTENSITÉ + PHASE - Faux négatif



FPM INTENSITÉ + PHASE - Faux positif

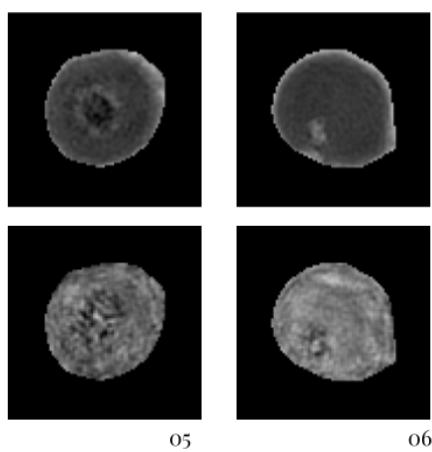


FIGURE 27: Exemple de faux négatifs et de faux positifs identifiés par le réseau pour l'entrée comme une image reconstruite par FPM avec des informations d'intensité et de phase.

5

CONCLUSION

Dans ce projet, nous travaillons à la reconstruction des images FPM et à la classification des cellules infectées par la malaria. Compte tenu des objectifs proposés au début de ce travail, nous avons pu développer un réseau de neurones pour effectuer la reconstruction des images FPM en améliorant la résolution de ces images, où nous avons effectué des tests et des comparaisons avec les méthodes de la littérature. Pour cela, il fallait d'abord une bonne compréhension de la méthode FPM et comme il s'agit d'une méthode récente, les études sur la méthode ont été poursuivies tout au long du projet. Nous avons pu obtenir certains paramètres que nous n'avions pas comme le positionnement de la LED de notre ensemble de données sur le paludisme, et aussi le développement de mesures pour l'amélioration du FPM. En outre, nous avons effectué la classification des cellules reconstruites avec une résolution améliorée par la méthode initialement proposée.

Bien que nous n'ayons obtenu qu'une petite différence entre le résultat de la classification avec l'utilisation de l'image de reconstruction fpm et l'utilisation de l'image centrale led à basse résolution, cette amélioration est significative dans la quantité totale de cellules analysées pour la définition d'un individu atteint de malaria, où un total de 200000 cellules sont analysées. Dans le cas de l'utilisation de l'image basse résolution, le nombre de faux négatifs serait d'environ 1360 cellules, tandis que dans le cas de l'image avec reconstruction fpm, le nombre de faux négatifs serait d'environ 900 cellules.

Le temps nécessaire pour appliquer la méthode proposée et pour effectuer la segmentation et la classification des cellules soit d'environ 35 seconds par cellule en effectuant un entraînement de 100 époques. Bien que ce soit une longue période de temps pour que cette étude soit appliquée dans l'industrie, l'étude reste cependant valable car elle montre l'amélioration de la résolution des imagettes de cellules par une reconstruction FPM et son amélioration de la classification des cellules.

Ce travail a été enrichissant à plusieurs égards, car j'ai eu l'occasion de travailler sur un sujet d'actualité qui m'a permis de développer des connaissances dans le domaine des FPM, mais aussi de mettre en application des connaissances développées pendant le master TRIED.

REFERENCES

- [1] *World Health Organization, Fact sheet about Malaria*, Consulté en 03 Août 2020. <https://www.who.int/news-room/fact-sheets/detail/malaria>.
- [2] G. Zheng, R. Horstmeyer, and C. Yang, “Wide-field, high-resolution fourier ptychographic microscopy,” *Nature photonics*, vol. 7, no. 9, p. 739, 2013.
- [3] G. Zheng, *Fourier ptychographic imaging : a MATLAB tutorial*. Morgan & Claypool Publishers, 2016.
- [4] R. W. Gerchberg, “A practical algorithm for the determination of phase from image and diffraction plane pictures,” *Optik*, vol. 35, pp. 237–246, 1972.
- [5] J. R. Fienup, “Reconstruction of an object from the modulus of its fourier transform,” *Optics letters*, vol. 3, no. 1, pp. 27–29, 1978.
- [6] J. R. Fienup, “Phase retrieval algorithms : a personal tour,” *Applied optics*, vol. 52, no. 1, pp. 45–56, 2013.
- [7] K. Wei, X. Jin, Y. Hu, and Q. Dai, “An effective guess for gerchberg-saxton-type algorithms,” in *Optoelectronic Imaging and Multimedia Technology III*, vol. 9273, p. 927330, International Society for Optics and Photonics, 2014.
- [8] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [9] S. Jiang, K. Guo, J. Liao, and G. Zheng, “Solving fourier ptychographic imaging problems via neural network modeling and tensorflow,” *Biomedical optics express*, vol. 9, no. 7, pp. 3306–3319, 2018.
- [10] M. Abadi, A. Agarwal, P. Barham, E. Brevdo, Z. Chen, C. Citro, G. S. Corrado, A. Davis, J. Dean, M. Devin, *et al.*, “Tensorflow : Large-scale machine learning on heterogeneous distributed systems,” *arXiv preprint arXiv :1603.04467*, 2016.
- [11] R. Horstmeyer, R. Y. Chen, B. Kappes, and B. Judkewitz, “Convolutional neural networks that teach microscopes how to image,” *CoRR*, vol. abs/1709.07223, 2017.
- [12] M. Kellman, E. Bostan, M. Chen, and L. Waller, “Data-driven design for fourier ptychographic microscopy,” in *2019 IEEE International Conference on Computational Photography (ICCP)*, pp. 1–8, IEEE, 2019.
- [13] M. Sun, X. Chen, Y. Zhu, D. Li, Q. Mu, and L. Xuan, “Neural network model combined with pupil recovery for fourier ptychographic microscopy,” *Opt. Express*, vol. 27, pp. 24161–24174, Aug 2019.
- [14] “Fourier ptychography.” <https://sites.google.com/site/gazheng/Fourier-Ptychography>. Accessed : 2020-09-24.
- [15] P. C. Konda, L. Loetgering, K. C. Zhou, S. Xu, A. R. Harvey, and R. Horstmeyer, “Fourier ptychography : current applications and future promises,” *Optics Express*, vol. 28, no. 7, pp. 9603–9630, 2020.
- [16] R. Eckert, Z. F. Phillips, and L. Waller, “Efficient illumination angle self-calibration in fourier ptychography,” *Applied optics*, vol. 57, no. 19, pp. 5434–5442, 2018.
- [17] L. Hou, H. Wang, J. Wang, and M. Xu, “Background-noise reduction for fourier ptychographic microscopy based on an improved thresholding method,” *Current Optics and Photonics*, vol. 2, no. 2, pp. 165–171, 2018.

-
- [18] A. Buades, B. Coll, and J.-M. Morel, “Non-local means denoising,” *Image Processing On Line*, vol. 1, pp. 208–212, 2011.
 - [19] N. Gourgue, “Détection des parasites de malaria par microscopie,” 2019.
 - [20] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
 - [21] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “Imagenet : A large-scale hierarchical image database,” in *2009 IEEE conference on computer vision and pattern recognition*, pp. 248–255, Ieee, 2009.
 - [22] M. R. Kellman, E. Bostan, N. A. Repina, and L. Waller, “Physics-based learned design : optimized coded-illumination for quantitative phase imaging,” *IEEE Transactions on Computational Imaging*, vol. 5, no. 3, pp. 344–353, 2019.
 - [23] M. Sun, X. Chen, Y. Zhu, D. Li, Q. Mu, and L. Xuan, “Neural network model combined with pupil recovery for fourier ptychographic microscopy,” *Optics Express*, vol. 27, no. 17, pp. 24161–24174, 2019.
 - [24] G. Bradski and A. Kaehler, “Opencv,” *Dr. Dobb’s journal of software tools*, vol. 3, 2000.
 - [25] W. Commons, “File :zernike polynomials2.pngs,” 2011. [Online ; accessed 2020-09-21].

6

ANNEXE

6.1 POLYNÔMES DE ZERNIKE

Le concept de front d'onde est quelque chose de fondamental pour le processus de détection et de correction des aberrations optiques. Le front d'onde est défini comme une surface construite d'ondes isophasiques. La structure de l'instrument dans lequel le front d'onde est soumis apporte des modifications au front d'onde et le rend imparfait. Ainsi, dans le cas d'un microscope, nous avons un instrument convergent et lorsque le front d'onde passe devant cet objet, la surface idéale du centre de l'onde est une sphère centrée sur le point focal, mais comme nous le disons souvent, nous n'avons pas un système optique parfait et cela provoque des aberrations dans le front d'onde. À titre d'exemple, nous pouvons voir la figure 28, où y représente l'objet dans lequel le front d'onde est soumis et passe ensuite à travers le système optique convergent où toutes les ondes devraient converger vers un point focal F, mais avec les aberrations, nous obtenons une tache à l'emplacement d'un point.

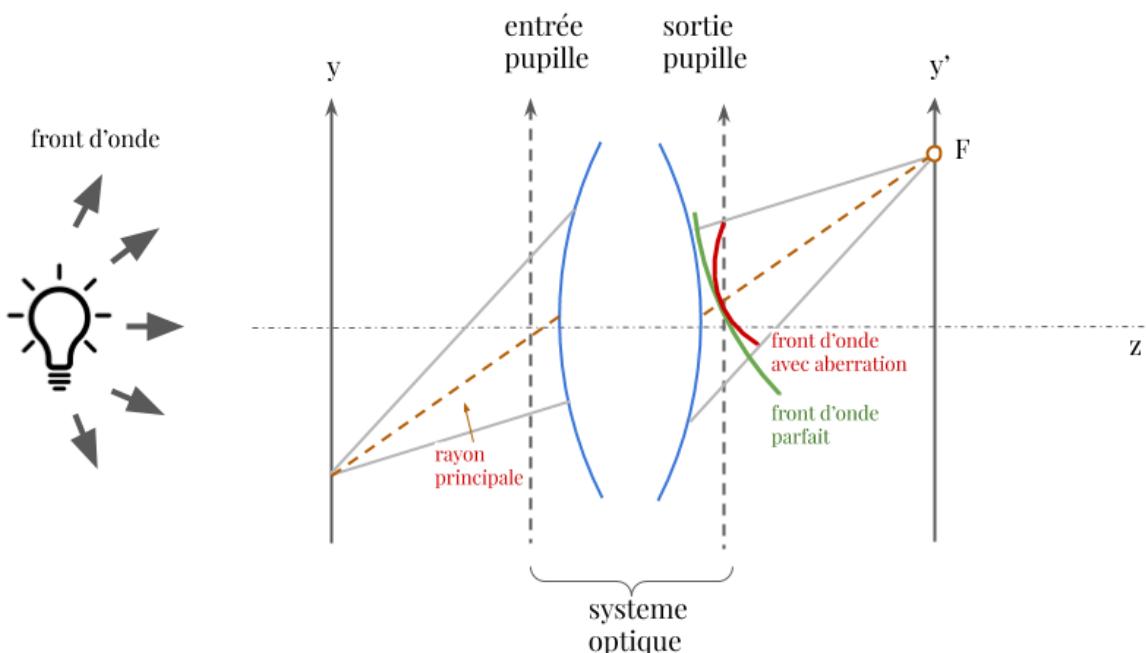


FIGURE 28: Représentation du passage d'un front d'onde par un système optique avec et sans aberrations.

En 1953, Frits Zernike, mathématicien, prix Nobel et inventeur de la microscopie à contraste de phase, a mis au point un système permettant de décrire ces aberrations optiques. Les polynômes de Zernike sont donc le nom donné à ce système d'équations mathématiques. Par conséquent, un front d'onde présentant des aberrations peut être représenté par la combinaison linéaire des polynômes de Zernike, c'est-à-dire une combinaison d'aberrations optiques connues. Dans la figure 29, nous avons des exemples des 21 premiers polynômes de Zernike.

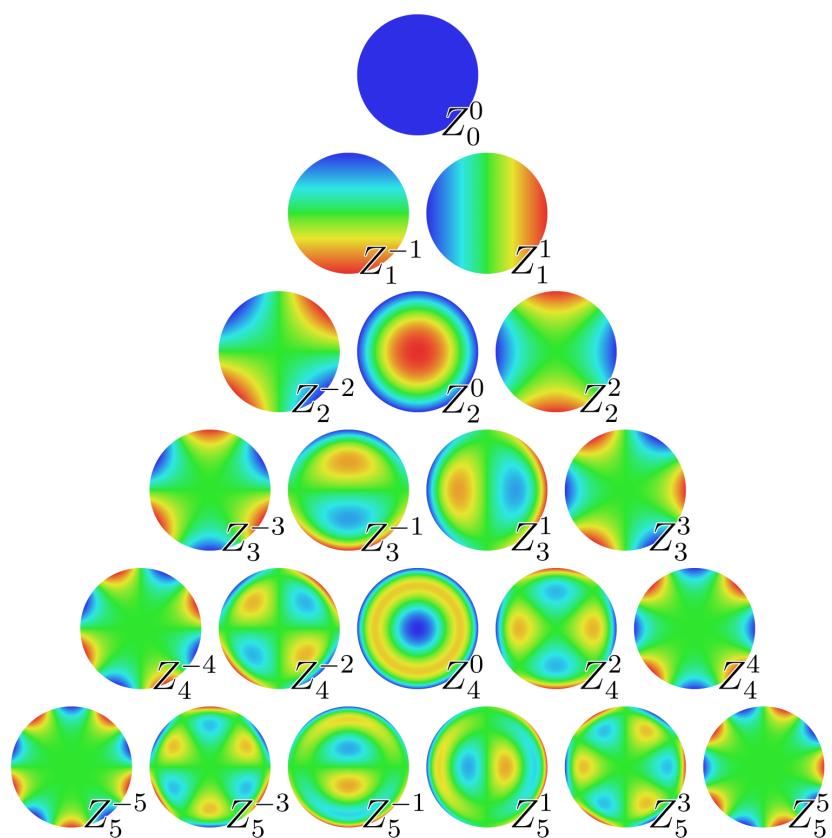


FIGURE 29: Exemple des 21 premiers polynômes de zernike. Source : (25)